

비모수통계 및 실습 (326.414)

11주차 연습문제 풀이

Junseok Lee

May 14, 2026

안내 사항

- 실습문제는 과제문제랑 별개이며, **성적평가에 반영되지 않습니다**. 수강생분들의 학습에 도움이 되기 위해 만들었으며 자유롭게 활용하시면 됩니다.
- 실습시간에 문제를 해설하며, 솔루션은 eTL에 공개됩니다.

문제 1

변수 $(X_1, \dots, X_n)$ 를 순위변환한 $(R_1, \dots, R_n)$, 그리고 변수 $(Y_1, \dots, Y_n)$ 를 순위변환한 $(S_1, \dots, S_n)$ 로 구성된 순위변환 데이터 $\{(R_1, S_1), \dots, (R_n, S_n)\}$ 는 각 순위변수의 표본평균이 $\bar{R} = \bar{S} = (n+1)/2$ 이다. 이때 각각의 표본분산을 S_{RR}, S_{SS} 으로 표현하면, r_s 를 다음과 같이 나타낼 수 있다.

$$r_s = \frac{1}{(n-1)\sqrt{S_{RR}S_{SS}}} \left[\sum_{i=1}^n R_i S_i - \left(\frac{n+1}{2} \right)^2 \right].$$

만약 각 변수의 순위에 동점이 없어 $\{R_1, \dots, R_n\} = \{S_1, \dots, S_n\} = \{1, \dots, n\}$ 이라면 $S_{RR} = S_{SS} = n(n+1)/12$ 이고,

$$r_s = 1 - \frac{6 \sum_{i=1}^n (R_i - S_i)^2}{n(n^2 - 1)}$$

이다. 위 사실들을 증명하여라.

풀이

$$S_{RR} = \frac{1}{n-1} \sum_{i=1}^n (R_i - \bar{R})^2, \quad S_{SS} = \frac{1}{n-1} \sum_{i=1}^n (S_i - \bar{S})^2$$

로 두면

$$r_s = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{(n-1)\sqrt{S_{RR}S_{SS}}}$$

이다.

먼저 분자를 전개하면

$$\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S}) = \sum_{i=1}^n R_i S_i - \bar{R} \sum_{i=1}^n S_i - \bar{S} \sum_{i=1}^n R_i + n\bar{R}\bar{S}.$$

그런데

$$\bar{R} = \bar{S} = \frac{n+1}{2}, \quad \sum_{i=1}^n R_i = n\bar{R}, \quad \sum_{i=1}^n S_i = n\bar{S}$$

이므로

$$\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S}) = \sum_{i=1}^n R_i S_i - n \left(\frac{n+1}{2} \right)^2.$$

따라서 표본분산의 정의와 맞는 식은

$$r_s = \frac{1}{(n-1)\sqrt{S_{RR}S_{SS}}} \left[\sum_{i=1}^n R_i S_i - n \left(\frac{n+1}{2} \right)^2 \right]$$

이다.

이제 각 변수의 순위에 동점이 없다고 하자. 그러면 $\{R_1, \dots, R_n\}$ 과 $\{S_1, \dots, S_n\}$ 은 모두 $\{1, \dots, n\}$ 의 순열이다. 따라서

$$\sum_{i=1}^n (R_i - \bar{R})^2 = \sum_{k=1}^n \left(k - \frac{n+1}{2} \right)^2 = \frac{n(n^2-1)}{12}.$$

그러므로

$$S_{RR} = \frac{1}{n-1} \sum_{i=1}^n (R_i - \bar{R})^2 = \frac{n(n^2-1)}{12(n-1)} = \frac{n(n+1)}{12}.$$

같은 방식으로

$$S_{SS} = \frac{n(n+1)}{12}$$

이다.

다음으로

$$D = \sum_{i=1}^n (R_i - S_i)^2$$

라고 두자. 그러면

$$D = \sum_{i=1}^n R_i^2 + \sum_{i=1}^n S_i^2 - 2 \sum_{i=1}^n R_i S_i.$$

동점이 없으므로

$$\sum_{i=1}^n R_i^2 = \sum_{i=1}^n S_i^2 = \sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}.$$

따라서

$$\sum_{i=1}^n R_i S_i = \frac{n(n+1)(2n+1)}{6} - \frac{D}{2}.$$

이를 r_s 의 식에 대입하면

$$\begin{aligned} \sum_{i=1}^n R_i S_i - n \left(\frac{n+1}{2} \right)^2 &= \frac{n(n+1)(2n+1)}{6} - \frac{D}{2} - \frac{n(n+1)^2}{4} \\ &= \frac{n(n^2-1)}{12} - \frac{D}{2}. \end{aligned}$$

또한

$$(n-1)\sqrt{S_{RR}S_{SS}} = (n-1)\frac{n(n+1)}{12} = \frac{n(n^2-1)}{12}.$$

따라서

$$\begin{aligned} r_s &= \frac{\frac{n(n^2-1)}{12} - \frac{D}{2}}{\frac{n(n^2-1)}{12}} \\ &= 1 - \frac{6D}{n(n^2-1)} \\ &= 1 - \frac{6 \sum_{i=1}^n (R_i - S_i)^2}{n(n^2-1)}. \end{aligned}$$

즉,

$$r_s = 1 - \frac{6 \sum_{i=1}^n (R_i - S_i)^2}{n(n^2-1)}$$

이다.

문제 2

X_i 들은 고정된 값으로 보고 $(Y_1, \dots, Y_n)$ 만을 유한모집단 $\{Y_1, \dots, Y_n\}$ 에서 랜덤비복원추출로 모두 다시 추출했을 때의 표본상관계수 r 의 분포를 r 의 순열분포라고 한다. 이 분포의 분산은 관측값 (X_i, Y_i) 와 상관없이 $1/(n-1)$ 임을 다음의 단계를 거쳐 증명하여라.

(a) 표본상관계수 r 의 분자 $r_1 = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$ 의 평균이 $E(r_1) = 0$ 임을 이용하여

$$\text{Var}(r_1) = \sum_{i=1}^n (X_i - \bar{X})^2 \text{Var}(Y_i) + \sum_{i \neq j} (X_i - \bar{X})(X_j - \bar{X}) \text{Cov}(Y_i, Y_j)$$

임을 보여라.

(b) 모든 $i \neq j$ 에 대해 $\text{Var}(Y_i) = S_{YY}/n$ 이며

$$\text{Cov}(Y_i, Y_j) = \frac{\sum_{i \neq j} (Y_i - \bar{Y})(Y_j - \bar{Y})}{n(n-1)}$$

이다.

(c) $\sum_{i \neq j} (X_i - \bar{X})(X_j - \bar{X}) = -S_{XX}$, 그리고 $\sum_{i \neq j} (Y_i - \bar{Y})(Y_j - \bar{Y}) = -S_{YY}$ 이다.

(d) 따라서,

$$\text{Var}(r) = \frac{\text{Var}(r_1)}{S_{XX}S_{YY}} = \frac{1}{n-1}$$

이다.

풀이

$$S_{XX} = \sum_{i=1}^n (X_i - \bar{X})^2, \quad S_{YY} = \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad r = \frac{r_1}{\sqrt{S_{XX}S_{YY}}}$$

로 둔다. 여기서

$$r_1 = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

이다.

- (a) X_i 들은 고정된 값이고, $(Y_1, \dots, Y_n)$ 만 랜덤비복원추출로 다시 배열된다고 보자. 이때 각 위치의 Y_i 는 유한모집단 $\{Y_1, \dots, Y_n\}$ 의 값들을 같은 확률로 갖는다. 따라서

$$E(Y_i) = \bar{Y}$$

이고,

$$E(r_1) = \sum_{i=1}^n (X_i - \bar{X}) E(Y_i - \bar{Y}) = 0.$$

따라서

$$\text{Var}(r_1) = E(r_1^2).$$

이제

$$\begin{aligned} r_1^2 &= \left\{ \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) \right\}^2 \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 (Y_i - \bar{Y})^2 \\ &\quad + \sum_{i \neq j} (X_i - \bar{X})(X_j - \bar{X})(Y_i - \bar{Y})(Y_j - \bar{Y}). \end{aligned}$$

양변에 기댓값을 취하면

$$\text{Var}(r_1) = \sum_{i=1}^n (X_i - \bar{X})^2 \text{Var}(Y_i) + \sum_{i \neq j} (X_i - \bar{X})(X_j - \bar{X}) \text{Cov}(Y_i, Y_j).$$

- (b) 먼저 한 위치 i 에 들어가는 Y_i 는 $Y_1, \dots, Y_n$ 중 하나를 확률 $1/n$ 으로 갖는다. 그러므로

$$\text{Var}(Y_i) = \frac{1}{n} \sum_{k=1}^n (Y_k - \bar{Y})^2 = \frac{S_{YY}}{n}.$$

또한 $i \neq j$ 이면 두 위치에는 서로 다른 두 값이 들어가므로

$$\begin{aligned} \text{Cov}(Y_i, Y_j) &= E\{(Y_i - \bar{Y})(Y_j - \bar{Y})\} \\ &= \frac{1}{n(n-1)} \sum_{k \neq l} (Y_k - \bar{Y})(Y_l - \bar{Y}). \end{aligned}$$

그런데

$$\begin{aligned} \sum_{k \neq l} (Y_k - \bar{Y})(Y_l - \bar{Y}) &= \left\{ \sum_{k=1}^n (Y_k - \bar{Y}) \right\}^2 - \sum_{k=1}^n (Y_k - \bar{Y})^2 \\ &= -S_{YY}. \end{aligned}$$

따라서

$$\text{Cov}(Y_i, Y_j) = -\frac{S_{YY}}{n(n-1)}.$$

- (c) 같은 항등식을 X 에 적용하면

$$\begin{aligned} \sum_{i \neq j} (X_i - \bar{X})(X_j - \bar{X}) &= \left\{ \sum_{i=1}^n (X_i - \bar{X}) \right\}^2 - \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= -S_{XX}. \end{aligned}$$

마찬가지로

$$\begin{aligned}\sum_{i \neq j} (Y_i - \bar{Y})(Y_j - \bar{Y}) &= \left\{ \sum_{i=1}^n (Y_i - \bar{Y}) \right\}^2 - \sum_{i=1}^n (Y_i - \bar{Y})^2 \\ &= -S_{YY}.\end{aligned}$$

(d) (a), (b), (c)를 이용하면

$$\begin{aligned}\text{Var}(r_1) &= \sum_{i=1}^n (X_i - \bar{X})^2 \frac{S_{YY}}{n} + \sum_{i \neq j} (X_i - \bar{X})(X_j - \bar{X}) \left(-\frac{S_{YY}}{n(n-1)} \right) \\ &= \frac{S_{XX}S_{YY}}{n} + (-S_{XX}) \left(-\frac{S_{YY}}{n(n-1)} \right) \\ &= \frac{S_{XX}S_{YY}}{n} + \frac{S_{XX}S_{YY}}{n(n-1)} \\ &= \frac{S_{XX}S_{YY}}{n-1}.\end{aligned}$$

따라서

$$\text{Var}(r) = \text{Var}\left(\frac{r_1}{\sqrt{S_{XX}S_{YY}}}\right) = \frac{\text{Var}(r_1)}{S_{XX}S_{YY}} = \frac{1}{n-1}.$$

즉, 순열분포에서 표본상관계수의 분산은 관측값 (X_i, Y_i) 의 구체적인 값과 상관없이

$$\text{Var}(r) = \frac{1}{n-1}$$

이다.

문제 3

(X, Y) 의 분포가 연속형이고 X, Y 가 서로 독립이거나 $\tau = 0$ 일 때, 켄달의 타우 통계량 τ_n 의 평균이 귀무가설이 사실일 때 $E(\tau_n) = 0$ 임을 보여라. 같은 조건에서 $\sum_{i < j} U_{ij}$ 의 분산이 $\text{Var}(\sum_{i < j} U_{ij}) = n(n-1)(2n+5)/18$ 임을 이용하여 $\text{Var}(\tau_n) = \frac{4n+10}{9n(n-1)}$ 임을 보여라. [$\text{Var}(\sum_{i < j} U_{ij})$ 의 계산은 Holander et al. (2013)을 참조]

풀이

$$U_{ij} = \text{sign}(X_i - X_j) \text{sign}(Y_i - Y_j) = \text{sign}\{(X_i - X_j)(Y_i - Y_j)\}, \quad i < j$$

로 둔다. 연속형 분포이므로 동점은 확률 0이다. 따라서 $U_{ij} = 1$ 이면 부합, $U_{ij} = -1$ 이면 비부합이다.

켄달의 타우 통계량을

$$\tau_n = \frac{2}{n(n-1)} \sum_{i < j} U_{ij}$$

로 쓴다. 먼저

$$E(U_{ij}) = 1 \cdot P(U_{ij} = 1) + (-1) \cdot P(U_{ij} = -1) = P(\text{부합}) - P(\text{비부합}) = \tau.$$

따라서

$$E(\tau_n) = \frac{2}{n(n-1)} \sum_{i < j} E(U_{ij}) = \frac{2}{n(n-1)} \binom{n}{2} \tau = \tau.$$

귀무가설이 사실일 때, 즉 X, Y 가 서로 독립이거나 $\tau = 0$ 이면

$$E(\tau_n) = 0$$

이다.

이제

$$K = \sum_{i < j} U_{ij}$$

라고 두면

$$\tau_n = \frac{2K}{n(n-1)}.$$

문제에서 주어진 바와 같이 같은 조건에서

$$\text{Var}(K) = \text{Var} \left(\sum_{i < j} U_{ij} \right) = \frac{n(n-1)(2n+5)}{18}$$

이다. 따라서

$$\begin{aligned} \text{Var}(\tau_n) &= \text{Var} \left(\frac{2K}{n(n-1)} \right) \\ &= \left\{ \frac{2}{n(n-1)} \right\}^2 \text{Var}(K) \\ &= \frac{4}{n^2(n-1)^2} \cdot \frac{n(n-1)(2n+5)}{18} \\ &= \frac{4(2n+5)}{18n(n-1)} \\ &= \frac{4n+10}{9n(n-1)}. \end{aligned}$$

그러므로

$$\boxed{\text{Var}(\tau_n) = \frac{4n+10}{9n(n-1)}}$$

이다.